

Examen Teórico – Parcial 3

Karime Jiménez Romero

1. ¿Cuál es la diferencia entre métodos de aprendizaje supervisado y no supervisado?
El aprendizaje supervisado se utiliza para entrenar un modelo con un conjunto de datos ya etiquetados y el no supervisado no tiene datos ya etiquetados, siendo su objetivo descubrir patrones ocultos, estructuras o relaciones en los datos.
2. ¿En cuál dataset se pueden aplicar métodos de Aprendizaje supervisado y en cuál método de Aprendizaje no supervisado?
En el primer dataset se podría usar aprendizaje supervisado porque la clase de “SleepStage” tiene una etiqueta (etapa del sueño) y además tiene variables predictoras como las frecuencias cerebrales (EEG).
En el segundo dataset se podría usar aprendizaje no supervisado porque no hay alguna columna con etiqueta, solo son valores numéricos.
3. ¿Cuál es la diferencia entre un problema de clasificación y uno de regresión?
Va a variar en el tipo de salida que se busca predecir. En un problema de clasificación la variable objetivo va a obtener valores de alguna categoría específica; en un problema de regresión la variable objetivo va a ser numérica y puede tomar cualquier valor en un rango.
4. ¿Cuál es la diferencia entre over-fitting y under-fitting?

Over-fitting es un sobreajuste, esto ocurre cuando un modelo llega a ser complejo, tiene muchas características y puede aprender particularidades irrelevantes, por lo que en los resultados puede tener un error muy bajo en los datos de entrenamiento y un error mayor en los datos nuevos.

Under-fitting es un subajuste, esto sucede cuando un modelo es muy simple para la complejidad del problema, teniendo muy pocos parámetros y /o mala selección de características, como resultado se tiene un modelo con un mal desempeño en los datos de entrenamiento y en los nuevos.
5. Basado en los valores anteriores, ¿qué ensayo dirías que corresponde a casos con over-fitting, under-fitting o balanceado?
 1. Ensayo 1: Over-fitting
 2. Ensayo 2: Under-fitting
 3. Ensayo 3: Under-fitting
 4. Ensayo 4: Over-fitting
 5. Ensayo 5: Balanceado
 6. Ensayo 6: Over-fitting
6. Contesta lo siguiente:
 1. Escribe las formulas de accuracy, precision, recall y f1-score

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 - score = \frac{Precision * Recall}{Precision + Recall}$$

2. Con base a la siguiente tabla, calcula accuracy, precision, recall y f1-score
 - a. Accuracy = 0.85
 - b. Precisión = 0.88
 - c. Recall = 0.8
 - d. F1-score = 0.419
3. A continuación tienes 3 descripciones de métricas en un problema de clasificación, indica a que métrica corresponde:

Descripción	Métrica
Proporción de predicciones correctas (tanto positivas como negativas) sobre el total de predicciones realizadas.	Accuracy
Porcentaje de verdaderos positivos identificados correctamente, respecto al total de positivos reales.	Recall
Porcentaje de aciertos entre los casos que el modelo predijo como positivos.	Precision

7. A continuación se presentan varias características de algoritmos de Machine Learning supervisado. Indica a qué método corresponde cada una de las siguientes afirmaciones:

- A) Análisis Discriminante
- B) Vecino más cercano (k-NN)
- C) Máquina de soporte vectorial (SVM)
- D) Árbol de decisión
- E) Bosques aleatorios

Nº	Característica	¿A qué método pertenece?
1	Asume que los datos de cada clase siguen una distribución normal (gaussiana)	A
2	No tiene fase de entrenamiento como tal; toda la predicción ocurre en tiempo real	B
3	Busca el hiperplano que maximiza el margen entre clases	C
4	Realiza múltiples divisiones binarias para clasificar los datos	D
5	Es sensible a la escala de las características, especialmente cuando se usa distancia euclidiana	D
6	Utiliza funciones núcleo (kernel) para trabajar con datos no lineales	C
7	Calcula la probabilidad de pertenencia a una clase bajo modelos estadísticos	A
8	Clasifica observaciones comparándolas con las más cercanas en el espacio de características	B
9	Utiliza múltiples árboles para reducir la varianza y mejorar la precisión	E
10	Puede sobreajustar fácilmente si el árbol es muy profundo	D
11	Su versión más simple se basa en modelos lineales con varianzas iguales por clase	A
12	Puede usar núcleos como RBF o polinomiales para separar clases de manera no lineal	C
13	Tiende a mejorar la generalización comparado con un solo árbol	E
14	Es altamente interpretativo cuando se trabaja con dos clases y pocos atributos	C
15	Es una combinación de muchos árboles contruidos sobre subconjuntos aleatorios del conjunto de entrenamiento	E

8. ¿Cuál es la diferencia entre Perceptron, Red Neuronal Artificial y Red Neuronal Convolutacional?

Perceptron es la unidad básica de una red neuronal, una sola neurona que recibe varias entradas. Este solo puede resolver problemas donde las clases puedan separarse linealmente.

Red Neuronal Artificial es una estructura compuesta por varios perceptrones en varias capas. Puede aprender patrones más complejos.

Red Neuronal Convolutacional utiliza capas para procesar datos con estructura espacial (imágenes). Puede detectar patrones simples como bordes o líneas hasta otros más complejos por medio de varias capas.

9. En el contexto de aprendizaje de una red neuronal, ¿qué es un epoch?

Se refiere al número de pasadas que el algoritmo ha realizado a través de todo el conjunto de datos de entrenamiento.

10. Lista las principales funciones de activación y describe la diferencia entre las funciones sigmoid y softmax
1. Sigmoid
 2. Tanh
 3. ReLu
 4. Softmax

Sigmoid es útil para problemas donde la salida es una sola probabilidad, solo hay dos clases. Softmax es útil para problemas donde se debe asignar una probabilidad a cada una de las clases posibles.