

The background features three large, thick, purple hand-drawn loops that overlap each other. One loop is on the left, one is on the right, and one is at the bottom, creating a stylized, abstract frame.

Redes

Neuronales


Redes neuronales

Perceptrón: el modelo de 1 sola neurona

Este es el modelo idealizado (si haces un modelo ya está idealizado)

Inputs
Capa de entrada

Neurona
Capa oculta



ej una cuadrática

Combinación lineal: suma y punto escalar, solo te genera otros vectores, combina datos de entrada por productos constantes

↑
mate

↑
geométrico

Vectores

→ matemáticos → 1, 2, 3, 4 y 6, 7, 8, 9 = 6 + 14 + 21 + 36 = 77

→ compu → $\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 6 \\ 7 \\ 8 \end{bmatrix} = 6, 14, 21, 36$

son los que nos interesan pq las salidas buscamos es virginica, versicolor y setosa

Outputs
Capas de salida



En esencia todo se puede linealizar no importa que tan complejo sea el comportamiento de la función

Función de activación

nosotros no vemos a linealizar todo vemos que una alternativa dif

Solo que el costo computacional también crece

Manipulación vs limpieza

Limpieza (ADE) análisis datos exploratorio → tenemos NA y vemos si los quitamos o los reemplazamos por algo

Manipulación → nuevas ff para la manipulación


Funciones de activación

- Función escalón




antes del 0 vale 0
después del 0 vale 1
(tiene o no tiene cancer)

- Función sigmoide




nos da valores de 0 al 1
se usan en problemas de probabilidad en binario (+ q es o no es cancer)

- Función ReLU



si el valor es - la asignas 0
si es + de 0 le asignas el valor x
para poder ayudar a disminuir entre ganancias

- Función atan



lo mismo que la sigmoide pero para usar valores negativos

- Función softmax



Antes 0.4
0.5
0.4
después (prob) 4/15
5/15
4/15
función cuando tienes múltiples neuronas


→ puntos de activación y capas y pesos reducidos

Capa salida
No necesariamente tiene que ser 1 sola salida

La red neuronal está calculando los dif pesos para que nos de la salida

Inputs
Capa de entrada

Neurona
Capa oculta ... Capa oculta m (podemos + # capas)



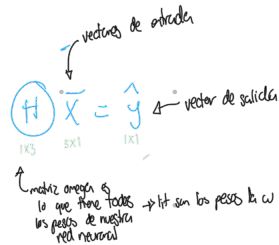

tenemos múltiples capas de salida pq tenemos dif clases (ej setosa, virginica, versicolor)

→ Si no es ninguna individualmente te dice que es setosa

Capa de entrada

Capa oculta

Capa de salida



Modelo subentrenado

Test loss \rightarrow el error se va a 0
Training loss \rightarrow el error se dispara

Modelo subentrenado

Error grande en ambos conjuntos

Modelo bien

Cuando ambos valores disminuyen

Entrenamiento \rightarrow la recombinación de los pesos suaviza entre 0 y 1, normaliza y así así todos los neuróns pueden influir de la misma forma al resultado y después los cambia

Forward propagation \rightarrow propagación ortograde \rightarrow variables de entrada, en pesos para encontrar el cálculo del error $e = \frac{1}{2} \sum (y_i - \hat{y}_i)^2$ el error puede ser muy grande o pequeño por eso se normaliza iniciando el entrenamiento de la red neuronal

$\hookrightarrow f(x) = f(x_1) + f(x_2) + \dots + f(x_n)$ \rightarrow encontrar el comp de futuros pesos de la función a partir de la derivada

Backward propagation \rightarrow propagación retrógrada \rightarrow retro de Adonis para encontrar el error y así que luego convergen peso




Con la función de Adonis calculas los futuros pesos en backward y forward \hookrightarrow al punto es que entre más iteraciones tu algoritmo llegará al mínimo error

Se le conoce como epoch

back \rightarrow forward

Error y nuevos pesos



En algún punto se estabiliza el error

La h se usa para darle un peso al gradiente y compararlo a la derivada

La h es el impulso que le das \rightarrow la velocidad a la que aprende la red neuronal

h bajo \rightarrow el error se reduce lento

h alto \rightarrow el error se reduce rápido pero no se recomienda por si tu base es muy variable al comportamiento es errático (menos error)

Volúmenes recomendados 0.01, 0.001

Redes neuronales

— Nosotros si podemos controlar epoch y funciones de activación

Función del error

es cuadrática → la función es cóncava → cuando queremos minimizar el error si encontramos un mínimo → tenemos siempre +

\hat{y} - y o costo
modelo groundtruth

$$e = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2$$

$$\hat{e} = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^5$$

\hat{e} mínimo local
vs mínimo global



así se comporta el error
pero solo para 1 percepción
si tienes + neuronas valdrá

→ la función de
costos batch
vease así



